



Universidad Peruana de Ciencias Aplicadas
Facultad de Ingeniería

Ciclo: 2026-02

Curso:

1ACC0216 – Fundamentos de Data Science

NRC: 4879

Profesora:

Nérída Isabel Manrique Tunque

Tema: Análisis Exploratorio, Visualización y Comunicación de Datos

Integrantes:

Nombres y Apellidos	Código
Addy Valentina Pinedo Saldaña	U20241D259
Edson Jair Ramos Vásquez	U20241F442
Jack Snayder Lima Huamani	U20241G263
Noelia Paquiyauri Tumbay	U20241F592
Tony Montesinos Condori	U20241F805

TB1 – Trabajo Parcial

1 Índice

1	Índice.....	2
2	Contexto y preguntas analíticas.....	3
2.1	Descripción del caso.....	3
2.2	Descripción del dataset.....	3
2.3	Áreas o personas interesadas en los resultados	3
2.4	Preguntas analíticas.....	4
2.5	Diccionario de variables.....	4
2.6	Clasificación de variables.....	6
2.7	Análisis breve.....	8
2.8	Calidad, análisis exploratorio y visualizaciones.....	10
2.8.1	Complejidad.....	10
2.8.2	Unicidad	11
2.8.3	Consistencia	11
2.8.3.1	Inconsistencias en la Composición de Huéspedes.....	12
2.8.3.2	Inconsistencias de Estancia.	13
2.8.3.3	Inconsistencias Categóricas.....	14
2.8.4	Validez	14
2.9	Análisis Univariado de Variables Críticas	16
2.10	Preparación y Transformación del Dataset	22
2.11	Análisis Bivariado.....	24
3	Comunicación de hallazgos.....	28
3.1	Síntesis de hallazgos.....	28
3.2	Conclusiones	30
3.3	Recomendaciones.....	31
3.4	Limitación del análisis	31
4	Bibliografía	32

2 Contexto y preguntas analíticas

2.1 Descripción del caso

El sector hotelero opera en un entorno dinámico caracterizado por la variabilidad constante de la demanda, la estacionalidad acentuada y la incertidumbre en el comportamiento de los clientes. En este contexto, el presente trabajo aborda la gestión operativa y comercial de dos establecimientos con perfiles de negocio distintos: un hotel urbano enfocado en estancias cortas y viajes institucionales, y un hotel de tipo resort orientado al turismo vacacional de mayor duración. Ambos establecimientos enfrentan problemas comunes que impactan su rentabilidad, tales como la alta tasa de cancelaciones imprevistas, la asignación eficiente de recursos como personal, espacios de estacionamiento, entre otros. Finalmente, el propósito de este análisis es transformar los registros de reservas en información útil para garantizar una adecuada toma de decisiones en la empresa.

2.2 Descripción del dataset

El conjunto de datos analizado, Hotel Booking Demand, está compuesto por 119,390 registros y 32 variables que recogen información sobre las reservas realizadas en ambos hoteles entre julio de 2015 y agosto de 2017. La información abarca desde el estado final de la reserva y la anticipación con la que se realizó, hasta el desglose cronológico de la fecha de llegada y la duración de la estancia en noches de semana y fines de semana. Asimismo, el dataset detalla la composición del grupo de huéspedes, el origen geográfico de los clientes, la tarifa diaria promedio cobrada, las políticas de depósito aplicadas, entre otros. Por otro lado, el conjunto de datos presenta deficiencias de calidad, tales como valores faltantes, registros duplicados e inconsistencias categóricas, los cuales serán abordados durante el tratamiento de los datos.

2.3 Áreas o personas interesadas en los resultados

Los resultados obtenidos a partir del análisis del dataset pueden ser de interés para diversas áreas relacionadas con la gestión de hoteles. En primer lugar, la gerencia general puede utilizar la información sobre el comportamiento de las reservas y cancelaciones para apoyar la toma de decisiones y evaluar el desempeño de cada tipo de hotel. De igual manera, el área de

reservas y recepción pueden beneficiarse del análisis de las cancelaciones y de la variación de la demanda, pues esta información permite anticipar periodos con mayor o menor cantidad de reservas y organizar de manera más eficiente la disponibilidad de habitaciones. Por otro lado, el área comercial y de marketing puede utilizar los resultados para identificar diferencias en la demanda entre el City Hotel y Resort Hotel, así como reconocer los periodos del año con mayor actividad. Esto podría servir para la planificación de promociones y estrategias orientadas a atraer clientes en épocas de menor demanda. Finalmente, el área de operaciones y planificación puede emplear los patrones identificados para organizar los recursos del hotel de acuerdo con la demanda esperada, como la disponibilidad de personal, habitaciones y con otros servicios necesarios para la atención de los huéspedes.

2.4 Preguntas analíticas

Pregunta de negocio	Pregunta analítica
¿Qué tipo de hotel concentra una mayor cantidad de reservas y cómo se comportan sus cancelaciones?	¿Qué proporción de las reservas corresponde a cada tipo de hotel y qué porcentaje de estas reservas termina en cancelación?
¿Cómo varía la cantidad de reservas a lo largo de los meses y qué patrones de demanda se observan según el tipo de hotel?	¿Qué meses presentan mayor y menor cantidad de reservas en cada tipo de hotel y cómo evoluciona la demanda durante el año?

2.5 Diccionario de variables

Descripción de las 32 variables del dataset Hotel Booking Demand.

N.º	Variable	Descripción
1	hotel	Tipo de hotel donde se realizó la reserva (City Hotel o Resort Hotel).
2	is_canceled	Indica si la reserva fue cancelada (1) o no (0).
3	lead_time	Días transcurridos entre el registro de la reserva y la fecha de llegada.
4	arrival_date_year	Año de la fecha de llegada.
5	arrival_date_month	Mes de la fecha de llegada (January a December).

6	arrival_date_week_number	Número de semana del año de la fecha de llegada.
7	arrival_date_day_of_month	Día del mes de la fecha de llegada.
8	stays_in_weekend_nights	Número de noches de fin de semana (sábado o domingo) reservadas u hospedadas.
9	stays_in_week_nights	Número de noches entre semana (lunes a viernes) reservadas o hospedadas.
10	adults	Número de adultos en la reserva.
11	children	Número de niños en la reserva.
12	babies	Número de bebés en la reserva.
13	meal	Tipo de régimen de comida reservado (SC/Undefined: sin paquete, BB: desayuno, HB: media pensión, FB: pensión completa).
14	country	País de origen del cliente (código ISO de 3 letras).
15	market_segment	Segmento de mercado de la reserva (por ejemplo, agencias de viaje TA, operadores turísticos TO, directo, corporativo).
16	distribution_channel	Canal de distribución por el que se realizó la reserva.
17	is_repeated_guest	Indica si el cliente ya se había hospedado antes (1) o no (0).
18	previous_cancellations	Número de reservas previas canceladas por el cliente antes de la reserva actual.
19	previous_bookings_not_canceled	Número de reservas previas no canceladas por el cliente antes de la reserva actual.
20	reserved_room_type	Código del tipo de habitación reservada (anonimizado).
21	assigned_room_type	Código del tipo de habitación asignada al huésped (anonimizado).
22	booking_changes	Número de cambios o modificaciones hechos a la reserva desde su registro hasta el check-in o la cancelación.

23	deposit_type	Tipo de depósito: No Deposit, Non Refund o Refundable.
24	agent	ID de la agencia de viajes que realizó la reserva.
25	company	ID de la empresa o entidad responsable de la reserva o del pago.
26	days_in_waiting_list	Días que la reserva estuvo en lista de espera antes de ser confirmada.
27	customer_type	Tipo de cliente: Contract, Group, Transient o Transient-party.
28	adr	Tarifa diaria promedio (suma de transacciones de alojamiento dividida entre el total de noches).
29	required_car_parking_spaces	Número de plazas de estacionamiento solicitadas por el cliente.
30	total_of_special_requests	Número de solicitudes especiales realizadas (por ejemplo, cama doble, piso alto).
31	reservation_status	Último estado de la reserva: Canceled, Check-Out o No-Show.
32	reservation_status_date	Fecha en que se estableció el último estado de la reserva.

2.6 Clasificación de variables

Clasificación de cada variable según su tipo, subtipo y escala de medición, independientemente de cómo R la almacena.

N.º	Variable	Tipo	Subtipo	Escala
1	hotel	Cualitativa	Dicotómica	Nominal
2	is_canceled	Cualitativa	Dicotómica	Nominal
3	lead_time	Cuantitativa	Discreta	Razón
4	arrival_date_year	Temporal	Año	Intervalo
5	arrival_date_month	Temporal	Mes	Ordinal

6	arrival_date_week_number	Temporal	Semana	Intervalo
7	arrival_date_day_of_month	Temporal	Día	Intervalo
8	stays_in_weekend_nights	Cuantitativa	Discreta	Razón
9	stays_in_week_nights	Cuantitativa	Discreta	Razón
10	adults	Cuantitativa	Discreta	Razón
11	children	Cuantitativa	Discreta	Razón
12	babies	Cuantitativa	Discreta	Razón
13	meal	Cualitativa	Nominal	Nominal
14	country	Cualitativa	Nominal	Nominal
15	market_segment	Cualitativa	Nominal	Nominal
16	distribution_channel	Cualitativa	Nominal	Nominal
17	is_repeated_guest	Cualitativa	Dicotómica	Nominal
18	previous_cancellations	Cuantitativa	Discreta	Razón
19	previous_bookings_not_canceled	Cuantitativa	Discreta	Razón
20	reserved_room_type	Cualitativa	Nominal	Nominal
21	assigned_room_type	Cualitativa	Nominal	Nominal
22	booking_changes	Cuantitativa	Discreta	Razón
23	deposit_type	Cualitativa	Nominal	Nominal
24	agent	Cualitativa	Nominal	Nominal
25	company	Cualitativa	Nominal	Nominal
26	days_in_waiting_list	Cuantitativa	Discreta	Razón
27	customer_type	Cualitativa	Nominal	Nominal
28	adr	Cuantitativa	Continua	Razón

29	required_car_parking_spaces	Cuantitativa	Discreta	Razón
30	total_of_special_requests	Cuantitativa	Discreta	Razón
31	reservation_status	Cualitativa	Nominal	Nominal
32	reservation_status_date	Temporal	Fecha	Intervalo

2.7 Análisis breve

Dimensiones y Muestra Inicial del Dataset

Dimensiones: El conjunto de datos cuenta con 119390 filas y 32 columnas.

Muestra de registros:

A continuación, se presenta una muestra representativa de los registros del conjunto de datos. Para facilitar la visualización y lectura en el informe, se han seleccionado las variables más críticas y relevantes para el análisis del negocio hotelero (tales como el tipo de establecimiento, estado de cancelación, tiempo de anticipación, segmento de mercado y tarifa diaria), omitiendo temporalmente las columnas restantes que se detallan en la estructura completa del dataset.

hotel	is_canceled	lead_time	arrival_date_year	arrival_date_month	market_segment	reserved_room_type	adr
<chr>	<db1>	<db1>	<db1>	<chr>	<chr>	<chr>	<db1>
1 Resort Ho...	0	342	2015	July	Direct	C	0
2 Resort Ho...	0	737	2015	July	Direct	C	0
3 Resort Ho...	0	7	2015	July	Direct	A	75
4 Resort Ho...	0	13	2015	July	Corporate	A	75
5 Resort Ho...	0	14	2015	July	Online TA	A	98
6 Resort Ho...	0	14	2015	July	Online TA	A	98
7 Resort Ho...	0	0	2015	July	Direct	C	107
8 Resort Ho...	0	9	2015	July	Direct	C	103
9 Resort Ho...	1	85	2015	July	Online TA	A	82
10 Resort Ho...	1	75	2015	July	Offline TA/TO	D	106.
11 Resort Ho...	1	23	2015	July	Online TA	E	123
12 Resort Ho...	0	35	2015	July	Online TA	D	145
13 Resort Ho...	0	68	2015	July	Online TA	D	97
14 Resort Ho...	0	18	2015	July	Online TA	G	155.
15 Resort Ho...	0	37	2015	July	Online TA	E	94.7
16 Resort Ho...	0	68	2015	July	Online TA	D	97
17 Resort Ho...	0	37	2015	July	Offline TA/TO	E	97.5
18 Resort Ho...	0	12	2015	July	Online TA	A	88.2
19 Resort Ho...	0	0	2015	July	Corporate	A	107.
20 Resort Ho...	0	7	2015	July	Direct	G	153

Estructura y Tipos de Datos Detectados

Al inspeccionar la estructura del dataset mediante las funciones de lectura de R, se identifican principalmente dos naturalezas técnicas en los datos numéricos:

Variables Numéricas / Cuantitativas (col_double): is_canceled, lead_time, arrival_date_year, arrival_date_week_number, arrival_date_day_of_month, stays_in_weekend_nights, stays_in_week_nights, adults, children, babies, is_repeated_guest, previous_cancellations, previous_bookings_not_canceled, booking_changes, agent, company, days_in_waiting_list, adr, required_car_parking_spaces, total_of_special_requests.

Variables de Tipo Carácter / Cualitativas (col_character): hotel, arrival_date_month, meal, country, market_segment, distribution_channel, reserved_room_type, assigned_room_type, deposit_type, customer_type, reservation_status.

Variables de Fecha (col_date): reservation_status_date.

```
.. hotel = col_character(),
.. is_canceled = col_double(),
.. lead_time = col_double(),
.. arrival_date_year = col_double(),
.. arrival_date_month = col_character(),
.. arrival_date_week_number = col_double(),
.. arrival_date_day_of_month = col_double(),
.. stays_in_weekend_nights = col_double(),
.. stays_in_week_nights = col_double(),
.. adults = col_double(),
.. children = col_double(),
.. babies = col_double(),
.. meal = col_character(),
.. country = col_character(),
.. market_segment = col_character(),
.. distribution_channel = col_character(),
.. is_repeated_guest = col_double(),
.. previous_cancellations = col_double(),
.. previous_bookings_not_canceled = col_double(),
.. reserved_room_type = col_character(),
.. assigned_room_type = col_character(),
```

```

..   adr = col_double(),
..   required_car_parking_spaces = col_double(),
..   total_of_special_requests = col_double(),
..   reservation_status = col_character(),
..   reservation_status_date = col_date(format = "")

```

Se identifica que R importa por defecto diversas variables categóricas y temporales como cadenas de texto (chr). Por ejemplo, variables como hotel, meal o market_segment deben ser convertidas posteriormente a factores (factor) para que los algoritmos de análisis estadístico y la generación de gráficos reconozcan correctamente sus niveles discretos. Asimismo, la variable reservation_status_date requiere una transformación explícita al formato de fecha (Date) para permitir un correcto filtrado y análisis temporal en las siguientes fases del proyecto.

2.8 Calidad, análisis exploratorio y visualizaciones

2.8.1 Completitud

Variable	Valores faltantes	Porcentaje
company	112593	94.3 %
agent	16340	13.7 %
country	488	0.409 %
children	4	0.003 %

Nota. Los resultados presentados en la tabla corresponden a un diagnóstico exploratorio ejecutado sobre la base de datos en su estado original (en crudo y sin transformaciones previas).

Se identificaron valores faltantes en cuatro variables. La variable “company” presenta la mayor cantidad de datos ausentes, con 112593 registros (94.3 %), seguida de “agent” con 16340 (13.7 %), “country” con 488 (0.409 %) y “children” con 4 (0.003 %). La presencia de valores faltantes no implica automáticamente un error, por lo que su tratamiento será determinado posteriormente según el contexto y la relevancia de cada variable para el análisis.

2.8.2 Unicidad

Indicador	Resultado
Registros totales	119390
Filas duplicadas exactas	31994
Porcentaje de duplicados	26.80 %

Nota. Los resultados presentados en la tabla corresponden a un diagnóstico exploratorio ejecutado sobre la base de datos en su estado original (en crudo y sin transformaciones previas).

Se identificaron 31994 filas duplicadas exactas, equivalentes al 26.80 % de los 119390 registros originales. Estas observaciones presentan la misma combinación de valores en todas las variables disponibles. Debido a esta coincidencia completa, se decidió conservar una sola ocurrencia de cada combinación y eliminar las copias adicionales en la versión preparada del dataset. Como resultado, `hotel_preparado` queda conformado por 87396 registros distintos. El dataset original se mantiene sin modificaciones.

2.8.3 Consistencia

La consistencia evalúa si los valores registrados mantienen relaciones lógicas entre sí, si las categorías se encuentran representadas de manera uniforme y si las variables temporales contienen combinaciones coherentes. Para esta evaluación se analizaron posibles contradicciones entre variables relacionadas dentro de una misma reserva, considerando la composición de huéspedes, las fechas de llegada, la duración y tarifa de la estancia, las categorías cualitativas y el estado final de las reservas.

Las comprobaciones se realizaron sobre el dataset original `hotel`, de modo que los resultados reflejen los problemas existentes antes de aplicar cualquier proceso de limpieza o transformación. Posteriormente, aquellos casos que requieran tratamiento serán corregidos únicamente en la versión preparada `hotel_preparado`.

2.8.3.1 Inconsistencias en la Composición de Huéspedes. Para evaluar la composición de los huéspedes se analizaron conjuntamente las variables *adults*, *children* y *babies*, que representan la cantidad de adultos, niños y bebés registrados en cada reserva. El diccionario del proyecto identifica estas tres variables como cantidades de huéspedes.

Como criterio exploratorio del equipo, se revisaron dos situaciones que podrían requerir análisis adicional: reservas que contienen niños o bebés, pero ningún adulto registrado, y reservas en las que la suma total de huéspedes es igual a cero. Estas condiciones no se consideran automáticamente errores, ya que el dataset no incluye una regla de negocio que permita confirmarlo; se identifican como registros potencialmente inconsistentes que requieren revisión.

Tipo de comprobación	Casos detectados
Menores (niños/bebés) sin adultos registrados	223
Total de huéspedes igual a cero	180

Nota. Los resultados presentados en la tabla corresponden a un diagnóstico exploratorio ejecutado sobre la base de datos en su estado original (en crudo y sin transformaciones previas).

Se identificaron 223 reservas en las que aparecen niños o bebés sin adultos registrados y 180 reservas cuyo número total de huéspedes es igual a cero. Estos casos se consideran observaciones que requieren revisión, pero no se modifican automáticamente, ya que con las variables disponibles no es posible confirmar si corresponden a errores de registro o a situaciones particulares de la reserva. El documento previo ya había identificado ambas condiciones y sus respectivas frecuencias.

2.8.3.2 Inconsistencias de Estancia. Para evaluar la consistencia temporal de las reservas, se analizaron conjuntamente las variables `stays_in_weekend_nights` y `stays_in_week_nights`, las cuales representan la cantidad de noches de fin de semana y de semana respectivamente. Según el modelo tradicional de gestión hotelera, la unidad mínima de pernoctación comercial exige que toda reserva confirmada cuente al menos con una noche de alojamiento registrada en alguna de ambas categorías.

Como criterio exploratorio del equipo, se revisó la existencia de registros donde ambas variables sumen cero. Estas condiciones no corresponden al funcionamiento estándar de pernoctación, ya que no generan ingresos por noches de estancia y escapan al modelo tradicional de alojamiento, identificándose como registros potencialmente inconsistentes que requieren revisión.

Comprobación	Casos detectados
Estancias con duración de cero noches (ambas variables en 0)	715

Nota. Los resultados presentados en la tabla corresponden a un diagnóstico exploratorio ejecutado sobre la base de datos en su estado original (en crudo y sin transformaciones previas).

Se identificaron 715 reservas en las que tanto las noches de fin de semana como las de semana registran un valor de cero. Esto se considera una observación anómala que requiere revisión, ya que, aunque operativamente podrían representar casos de uso diurno, la estructura del dataset carece de un indicador explícito que permita confirmarlo, por lo que se tipifica como una inconsistencia temporal frente a un modelo estándar.

2.8.3.3 Inconsistencias Categóricas. Para evaluar la estandarización de los datos cualitativos, se inspeccionaron las variables categóricas del negocio, identificando el uso de etiquetas genéricas o no definidas ("Undefined"). En una gestión hotelera rigurosa, las variables de clasificación deben pertenecer a catálogos cerrados y estrictamente definidos.

Variable	Categoría Evaluada	Casos detectados
Segmento de mercado (market_segment)	Undefined	2
Canal de distribución (distribution_channel)	Undefined	5

Nota. Los resultados presentados en la tabla corresponden a un diagnóstico exploratorio ejecutado sobre la base de datos en su estado original (en crudo y sin transformaciones previas).

Se detectó la presencia cruzada de la categoría "Undefined" en 2 dimensiones: el segmento de mercado (market_segment) y el canal de distribución (distribution_channel). Esta condición denota vacíos en la captura de información del sistema de gestión, generando ambigüedades analíticas que impiden clasificar correctamente dichas reservas dentro de la operativa comercial del hotel.

2.8.4 Validez

La validez evalúa si los valores registrados cumplen con los dominios, categorías, formatos y rangos esperados para cada variable. En este análisis se revisaron variables cuyo conjunto de valores válidos puede establecerse a partir del diccionario de datos.

El enunciado del trabajo establece que dentro de la dimensión de validez deben revisarse posibles valores negativos, categorías no permitidas, rangos imposibles o formatos incorrectos.

Problema de Validez	Casos detectados
Tarifa diaria negativa	1
Tarifa diaria extrema	1
Tarifas en cero	1959
Código de país con formato incorrecto	1279

Nota. Los resultados presentados en la tabla corresponden a un diagnóstico exploratorio ejecutado sobre la base de datos en su estado original (en crudo y sin transformaciones previas).

Infracciones de dominio en la Tarifa Diaria Promedio (adr): Se identificaron dos registros que vulneran la coherencia económica del negocio. En primer lugar, se detectó un valor negativo de -6.38, el cual es un error crítico inadmisible en una transacción comercial de venta. En segundo lugar, se encontró un valor extremo aislado de 5,400.0 unidades monetarias, el cual distorsiona desproporcionadamente la escala de precios del establecimiento frente a la mediana del conjunto de datos (94.58). Ambos registros constituyen anomalías no plausibles que justifican su exclusión técnica en la etapa de preparación.

Tarifas en cero (adr == 0): Se identificaron 1,959 reservas con tarifa diaria igual a cero. Tras contrastar estos registros con el estado de la reserva, se constató que el 89.1% (1,746 observaciones) corresponde a estancias completadas con normalidad (Check-Out), concentradas principalmente en el segmento de cortesía (Complementary) y convenios corporativos. Esto demuestra que no se trata de errores de cobro ni de reservas canceladas, sino de políticas comerciales legítimas de la cadena (tales como programas de fidelidad o estancias de empleados). Por ello, se clasifican como casos válidos que se deben conservar para no subestimar la ocupación física del hotel.

Incumplimiento de formato en País de Origen (country): Se detectaron 1,279 registros con el código CN de dos caracteres. Esto vulnera la regla de estandarización fijada en el diccionario de datos, la cual exige estrictamente el formato internacional ISO 3166-1 alpha-3 (códigos de tres letras). Esta discrepancia representa un riesgo

analítico directo, ya que en el dataset coexisten 999 reservas registradas bajo el código oficial CHN, dividiendo artificialmente las estadísticas del turismo emisor procedente de China.

2.9 **Análisis Univariado de Variables Críticas**

Para cumplir con el análisis univariado exigido, se estudiaron las variables cuantitativas continuas más relevantes del negocio hotelero: la Tarifa Diaria Promedio (adr) y el Tiempo de Anticipación (lead_time). El análisis integró medidas de tendencia central, dispersión, tablas de frecuencias agrupadas por intervalos con sus respectivos porcentajes, y el soporte visual de histogramas y diagramas de caja (Boxplots) para la detección de valores atípicos mediante el Rango Intercuartílico.

Tarifa Diaria Promedio (adr):


Medidas Descriptivas

Media: 101.83 | Mediana: 94.58 | Desviación Estándar: 50.54 | Mínimo: -6.38 |
Máximo: 5,400.00

Tabla de Frecuencias y Porcentajes por Rangos

Intervalo de Tarifa (adr)	Frecuencia (n)	Porcentaje (%)
Negativo / Cero (≤ 0)	1960	1.64%
0.01 - 50.00	10,037	8.41%
50.01 - 100.00	55,641	46.60%
100.01 - 150.00	35,244	29.52%
150.01 - 200.00	11,579	9.70%
200.01 - 500.00	4,926	4.13%
Más de 500.00	3	0.0025%
Total	119390	100.00%


Histograma: Tarifa Diaria Promedio (adr)



Asimetría y distorsión de escala: La presencia del valor atípico extremo aislado de 5,400.00 fuerza al eje horizontal a expandirse artificialmente hasta más de 5,000 unidades monetarias. Esto produce una compresión visual severa, agrupando prácticamente la totalidad de las reservas en un bloque estrecho cercano al origen.

Comportamiento general: A pesar de la distorsión, se evidencia una distribución asimétrica a la derecha con una concentración masiva entre 0 y 200, y una cola superior de densidad nula que finaliza en el valor extremo superior.

Boxplot: Detección de Outliers en ADR



El diagrama de caja (Boxplot) exhibe una concentración pronunciada de los datos en la base del gráfico, delimitada entre el primer cuartil ($Q_1 = 69.29$) y el tercer cuartil ($Q_3 = 126.00$), con una mediana de 94.58 unidades monetarias. Aplicando la regla del Rango Intercuartílico (RIC = 56.71), se identifica un límite superior de Tukey de 211.06, a partir del cual se despliega una densa acumulación de valores atípicos superiores que corresponden a tarifas de temporada alta. En el extremo superior destaca un valor atípico severo de 5,400.00, el cual rompe la escala del gráfico y distorsiona la media aritmética. Por su parte, la tarifa mínima negativa (-6.38) se sitúa en el extremo

inferior del bigote y, aunque queda contenida dentro del umbral matemático de Tukey ($Q_1 - 1.5 \cdot RIC = -15.78$), representa una infracción crítica al dominio económico del negocio. Ambos casos extremos sustentan técnicamente su posterior exclusión en la fase de preparación de datos.

Tiempo de Anticipación de la Reserva (lead_time):


Medidas Descriptivas

Media: 104.01 | Mediana: 69.00 | Desviación Estándar: 106.86 | Mínimo: 0.00 | Máximo: 737.00

Tabla de Frecuencias y Porcentajes por Rangos

Intervalo de Anticipación (lead_time)	Frecuencia (n)	Porcentaje (%)
Mismo día (0 días)	6345	5.31%
1 a 30 días	32361	27.11%
31 a 90 días	29553	24.75%
91 a 180 días	26439	22.15%
181 a 365 días	21544	18.05%
Más de 1 año (>365 días)	3148	2.64%
Total	119390	100.00%


Histograma: Tiempo de Anticipación (lead_time)



Comportamiento unimodal asimétrico: Presenta una distribución fuertemente asimétrica hacia la derecha con la moda en reservas de muy corto plazo (0 a 30 días, que concentra más del 32% de los casos).

Disminución progresiva: Conforme aumenta la anticipación, la frecuencia desciende de forma suave y continua, conformando una cola derecha alargada que se extiende hasta observaciones superiores a los 365 días (con un valor máximo de 737 días). A diferencia de adr, la cola no está vacía, sino que muestra una densidad decreciente pero continua de reservas a largo plazo.

Boxplot: Detección de Outliers en lead_time



Estructura central y asimetría: La caja intercuartílica concentra el 50% central de los datos entre el primer cuartil ($Q_1 = 18.00$ días) y el tercer cuartil ($Q_3 = 160.00$ días), registrando una mediana de 69.00 días. La proximidad de la mediana hacia el borde inferior de la caja (Q_1) confirma visualmente una marcada asimetría positiva hacia la derecha, indicando que la mayoría de los clientes gestiona su reserva con menos de dos meses y medio de anticipación.

Aplicación de la regla del Rango Intercuartílico ($1.5 \cdot \text{RIC}$): Con un rango intercuartílico de $\text{RIC} = Q_3 - Q_1 = 142.00$ días, el límite superior teórico de Tukey se ubica en:

$$\text{Límite Superior} = Q_3 + 1.5 \cdot \text{RIC} = 160.00 + 1.5(142.00) = 373.00 \text{ días}$$

A partir de este umbral se detecta una columna continua de 3005 valores atípicos superiores (2.52% del conjunto de datos), los cuales se extienden progresivamente hasta alcanzar un valor máximo extremo de 737.00 días (más de dos años de anticipación). Hacia la parte inferior, el límite matemático teórico es negativo ($18 - 213 = -195.00$), por lo que el bigote inferior concluye en el mínimo del dominio (0 días, reservas para el mismo día de llegada), sin presencia de valores atípicos inferiores.

2.10 Preparación y Transformación del Dataset

A partir de los diagnósticos de calidad y el análisis exploratorio univariado realizados en las secciones anteriores, se procedió a construir una nueva versión optimizada del conjunto de datos denominada `hotel_preparado`, con el fin de asegurar la confiabilidad en las siguientes fases de análisis sin alterar el archivo original.

Problema Identificado	Variable(s)	Decisión tomada	Justificación
Valores Faltantes o Cadenas Vacías	Múltiples variables (ej. celdas en blanco o nulas)	Estandarización a NA en la importación (<code>na = c("", "NA", "NULL")</code>)	Permite que R reconozca correctamente las celdas vacías o nulas como valores perdidos (NA) desde la lectura inicial, evitando que se procesen como texto válido y asegurando un diagnóstico de completitud preciso.
Registros Duplicados (31,994 filas)	Todas las columnas	Excluir copias (Conservar registro único con <code>distinct()</code>)	Al carecer de un identificador de transacción (<code>Reservation_ID</code>), las reservas en bloque de

			agencias y redundancias de captura generan filas idénticas en las 32 variables. Su depuración a 87,394 registros es indispensable para evaluar decisiones independientes de clientes y evitar la sobreestimación de cancelaciones en touroperadores.
Valores Inválidos / Errores Críticos	adr (Tarifa Diaria: -6.38 y 5,400)	Excluir, justificándolo (filter)	El valor de -6.38 vulnera el dominio económico mínimo de venta de alojamiento, mientras que 5,400.00 representa un error de digitación que distorsiona desproporcionadamente la media aritmética.
Códigos de Error / Categorías Indefinidas	market_segment, distribution_channel (etiquetas "Undefined")	Recodificar a NA (na_if)	Constituyen vacíos de captura o fallos de integración en el sistema. No existe un canal comercial ni agencia denominada "Undefined", por lo que aislarlos como valores perdidos evita ambigüedades en cruces de distribución.
Tipos de Datos Inadecuados	Variables categóricas y temporales	Transformar (Conversión a factor y Date)	Es un requerimiento técnico indispensable en R para corregir la escala de medición. Permite que las funciones estadísticas reconozcan los niveles fijos de las categorías y que el sistema procese correctamente las líneas de tiempo para el análisis estacional de la demanda.

2.11 Análisis Bivariado

Análisis Bivariado: Relación entre el Tipo de Hotel y el Estado de Cancelación




Tabla de Contingencia

Tipo de Hotel	No Cancelado (0)	Cancelado (1)	Total Reservas (n)	Participación (%)	Tasa de Cancelación
City Hotel	37379	16048	53427	61.13%	30.04%
Resort Hotel	25991	7976	33967	38.87%	23.48%
Total General	63370 (72.51%)	24024 (27.49%)	87394	100.00%	27.49%

Lectura del gráfico: El análisis bivariado revela una marcada asimetría tanto en la cuota de mercado como en el comportamiento de abandono. El City Hotel concentra la mayor parte de la operación con el 61.1% de las reservas totales (53427 registros), asumiendo una tasa de cancelación del 30.0% (16048 reservas). En contraste, el Resort Hotel representa el 38.9% de la demanda (33967 registros) y presenta un comportamiento significativamente más estable, con una tasa de cancelación del 23.5% (7976 reservas).

Respuesta a la Pregunta Analítica 1: El City Hotel concentra la mayor cantidad de reservas con el 61.1% del volumen global, experimentando una tasa de cancelación del 30.0%. Por su parte, el Resort Hotel abarca el 38.9% restante con una tasa de cancelación de 23.5%. Esto evidencia que el modelo urbano sufre una mayor volatilidad comercial frente al establecimiento vacacional.

Visualización Temporal: Estacionalidad y Evolución Mensual de la Demanda




Tabla de Resumen Mensual

Mes de Llegada (arrival_date_month)	City Hotel (n)	Resort Hotel (n)	Total Cadena (n)	Patrón Estacional
January	2,730 (Mínimo)	1,963 (Mínimo)	4,693	Temporada baja invernal
February	3,605	2,493	6,098	Recuperación temprana
March	4,855	2,656	7,511	Primavera / Inicio de turismo corporativo
April	5,080	2,828	7,908	Demanda sostenida

May	5,413	2,942	8,355	Pico de primavera
June	5,005	2,760	7,765	Transición previa al verano
July	5,744	4,313	10,057	Inicio de temporada alta vacacional
August	6,591 (Máximo)	4,666 (Máximo)	11,257 (Pico Anual)	Pleno verano boreal (Máxima afluencia)
September	4,240	2,450	6,690	Descenso post-vacacional
October	4,208	2,726	6,934	Otoño sostenido
November	2,942	2,053	4,995	Caída preinvernal
December	3,014	2,117	5,131	Festividades de fin de año

En el Resort Hotel, la demanda se mantiene moderada y plana entre enero y junio (oscilando entre 1900 y 2900 reservas), experimentando un crecimiento exponencial durante los meses de verano boreal (julio y agosto), donde alcanza su pico máximo histórico de 4666 reservas en agosto (más del doble que en enero). A partir de septiembre, la afluencia desciende bruscamente hacia niveles invernales.

En el City Hotel, la afluencia es más amplia y sostenida desde la primavera hasta el verano (superando las 5000 reservas mensuales entre abril y agosto). Si bien registra su máximo anual en agosto (6591 reservas), presenta una menor dependencia estacional extrema que el complejo vacacional, registrando su valle en el mes de enero (2730 reservas).

Respuesta a la Pregunta Analítica 2:

Meses con mayor demanda: En ambos establecimientos el mes con mayor volumen es agosto (6591 reservas en City Hotel y 4666 en Resort Hotel), seguido de julio.

Meses con menor demanda: El punto más bajo de reservas para ambos ocurre en enero (2730 en City Hotel y 1963 en Resort Hotel), junto con noviembre.

El City Hotel exhibe una demanda operativa prolongada que abarca de marzo a agosto (apoyada en viajes de negocios y turismo urbano), mientras que el Resort Hotel presenta una concentración hiperestacional concentrada casi exclusivamente en el verano europeo (julio-agosto), sufriendo una pronunciada subutilización de capacidad en otoño e invierno.

3 Comunicación de hallazgos

3.1 Síntesis de hallazgos

Siguiendo el principio de transformar volúmenes de gráficos exploratorios en información accionable, la siguiente síntesis selecciona únicamente los descubrimientos más críticos obtenidos tras auditar la calidad de los datos, realizar el análisis univariado y ejecutar los cruces bivariados y temporales del proyecto. Cada elemento condensa el dato duro y su impacto directo.

Hallazgo	Evidencia que lo respalda	Interpretación
El City Hotel concentra la mayoría de clientes, pero casi 1 de cada 3 cancela su reserva	Tabla de contingencia y gráfico bivariado: el City Hotel representa el 61.1% de todas las reservas (53,427 reservas), pero tiene una tasa de cancelación del 30.0% (16,048 cancelaciones). En cambio, el Resort Hotel abarca el 38.9% restante y	El hotel de ciudad es el principal motor de ventas de la cadena. Sin embargo, que el 30% de sus clientes cancele representa un problema operativo grave: habitaciones que quedan vacías a último minuto y pérdida directa de ingresos. Esto obliga a exigir cobros por

	registra una cancelación menor, del 23.5%.	adelantado o penalidades para asegurar las reservas.
Fuerte dependencia del verano en el Resort Hotel frente a una demanda constante en el City Hotel	Visualización temporal y tabla mensual: el Resort Hotel experimenta un incremento de reservas de más del doble (+137.7%) entre su punto más bajo en enero (1,963 reservas) y su pico de agosto (4,666 reservas). En contraste, el City Hotel mantiene una afluencia superior a 4,200 reservas mensuales a lo largo de 8 meses del año.	El Resort Hotel sufre un problema clásico de temporada baja: sus habitaciones quedan prácticamente vacías en invierno al depender exclusivamente del turismo de sol y playa. El City Hotel, en cambio, tiene un flujo más seguro y parejo porque recibe viajeros de negocios y turistas urbanos de forma continua.
Poca flexibilidad en las tarifas: la gran mayoría de clientes paga entre 50 y 150 por noche	Histograma y tabla de frecuencias de ADR: el 76.1% de las reservas se concentra en un rango estrecho de 50 a 150 unidades monetarias, con un precio típico central (mediana de 94.58).	Los hoteles aplican tarifas muy similares todo el tiempo. Esto indica que no están aprovechando los meses de verano para cobrar más a quienes están dispuestos a pagar tarifas altas, ni bajan lo suficiente los precios en invierno para atraer huéspedes cuando las habitaciones están vacías.
Gran cantidad de reservas repetidas y datos con error en el sistema original	Diagnóstico de calidad: se detectaron 31,994 filas duplicadas exactas (el 26.8% de toda la base), además de dos precios imposibles: una tarifa negativa de -6.38 y un cobro aislado de 5,400.	Muchas agencias de viajes reservaron bloques enteros de habitaciones idénticas que luego cancelaron en grupo. Si no se eliminaban estas copias repetidas y las tarifas erróneas, los cálculos habrían inflado falsamente la tasa de cancelación y distorsionado el precio promedio del hotel

En conjunto, la síntesis de estos hallazgos demuestra que los dos establecimientos analizados operan bajo realidades comerciales profundamente heterogéneas. Mientras que el desafío prioritario del City Hotel radica en la mitigación del riesgo operativo por cancelaciones imprevistas (que alcanzan casi un tercio de su

volumen), el reto medular del Resort Hotel reside en la gestión de su estacionalidad extrema y la reactivación de su capacidad instalada durante el periodo invernal. Asimismo, la contrastación entre los datos en crudo y la muestra preparada confirma que las decisiones estratégicas de mercadotecnia y asignación de tarifas solo resultan confiables tras someter el sistema a un protocolo riguroso de auditoría y depuración estadística.

3.2 Conclusiones

El hotel urbano representa el motor comercial de la cadena al absorber el 61.1% de la demanda total (53,427 reservas), superando ampliamente al Resort Hotel que captura el 38.9% (33,967 reservas).

A pesar de su mayor volumen, el City Hotel enfrenta un riesgo crítico de abandono con una tasa de cancelación del 30.0% (16,048 reservas no concretadas), resultando notablemente superior a la del Resort Hotel (23.5%, equivalente a 7,976 cancelaciones). Esto demuestra que el modelo urbano asume una mayor merma en sus ingresos proyectados.

Mientras que el City Hotel mantiene una afluencia sostenida y estable que supera las 4,200 reservas mensuales durante ocho meses del año, el Resort Hotel sufre una hiperdependencia de la temporada vacacional de verano boreal (disparándose un +137.7% entre el mínimo de enero con 1,963 reservas y el pico de agosto con 4,666 reservas).

La auditoría diagnóstica evidenció que el dataset en crudo presentaba un 26.8% de redundancias exactas (31,994 registros) asociadas a bloques masivos de agencias de viaje y touroperadores, además de cobros atípicos e inválidos (-6.38 y 5,400.0 en tarifa diaria). Su depuración a una muestra preparada de 87,394 observaciones fue un

prerrequisito técnico indispensable para evitar sesgos en el cálculo de las cancelaciones reales.

3.3 Recomendaciones

Dado que casi 1 de cada 3 reservas es cancelada (30.0%), la gerencia general y el área de reservas deben implementar tarifas diferenciadas no reembolsables con un descuento del 5% al 10%, o exigir anticipos obligatorios equivalentes a la primera noche de estancia para reservas con más de 30 días de anticipación (lead_time). Esta medida transfiere el compromiso al cliente, reduce el abandono imprevisto y asegura liquidez inmediata.

Para mitigar la capacidad ociosa durante el periodo invernal (donde la demanda cae a cerca de 2,000 reservas mensuales entre noviembre y enero), el departamento de mercadotecnia debe diseñar paquetes de fin de semana para el turismo de proximidad, programas de bienestar (spa/wellness) y convenios con empresas para convenciones y retiros de trabajo fuera de los meses de julio y agosto.

3.4 Limitación del análisis

El análisis solo abarca los datos de los años 2015 a 2017. Por lo tanto, las conclusiones sobre cancelaciones y estacionalidad se aplican solo a ese periodo y no reflejan eventos posteriores, como cambios económicos actuales.

3.5 Anexo de Uso Responsable de IA

Herramienta empleada: Gemini.

Finalidad: Soporte analítico para la depuración de sintaxis en lenguaje R (ggplot2, dplyr, scales) y revisión de consistencia numérica en cruces bivariados.

Control humano: Los códigos generados fueron validados, ejecutados y contrastados por los integrantes del grupo contra los archivos hotel_bookings_original.csv y hotel_bookings_preparado.csv en RStudio.

4 Bibliografía

Antonio, N., Almeida, A., & Nunes, L. (2019). Hotel booking demand datasets. *Data in Brief*, 22, 41-49. <https://doi.org/10.1016/j.dib.2018.11.126>